大数据课程设计

作者　陈哲安 王源毅

学院　理学院

专业　数学与应用数学

学号　2018212432 2018212466

班级　2018214101

不实信息爬虫部分

用到的modules:

```
from selenium import webdriver
from pyquery import PyQuery as pq
import csv
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import time
from multiprocessing import Process
```

首先设置一个返回一个带头模式的浏览器的函数start_webdriver()

```
def start_webdriver():
    # 登录浏览器
    options = webdriver.FirefoxOptions()
    # options.add_argument('--headless')
    # options.add_argument('--no-sandbox')
    # options.add_argument('--disable-dev-shm-usage')
    driver =
webdriver.Firefox(options=options,executable_path='/usr/local/bin/geckodriver')
    return driver
```

然后利用**start_webdriver()**函数先启动一个浏览器,获取cookies信息,以便后面多线程里的浏览器使用

```
# 手动到微博的登录界面然后登录
driver=start_webdriver()
driver.get('https://weibo.com/login.php')
#手动登录完毕之后获取 cookies
cookies=driver.get_cookies()
driver.close()
```

data_explorer(driver,href):

让driver跳转到href对应的界面后,运用我们对于不实信息网页分析得到的各个我们所需信息的xpath,进行相应的爬取.对于每条不实信息,我们总共需要获取以下内容:

```
[
        "举报人",
        "性别(举)",
        "所在地区(举)",
```

```
            "被举报人",
            "性别(被)",
            "所在地区(被)",
            "被举报人的微博主页",
            "被举报内容的微博网址",
            "被举报人信用等级",
            "被举报人是否是微博会员",
            "不实信息内有无超链接",
            "不实信息具体内容",
            "该举报在不实信息网站原文链接",
            "站方判定",
            "站方判定(全)",
            "被举报微博发布时间",
            "被举报微博发布时间(精确)",
    ]
```

data_explorer(driver,href)函数运行的思路是:

- 首先寻找页面右边被举报人的区域里面是否有"阅读全文"的标签，如果有的话，就把阅读原文的标签全部点击
- 然后，根据各个xpath对于网页进行扫描,获取需要的信息
- 将这些信息汇总成一个列表，返回

```
    def data_explorer(driver,href):
        Yuanwen_flag=0
        try:
            #把 右边的 阅读全文 全部点了
            t=driver.find_elements_by_xpath("//div[@class='part_report
    part_report_alone clearfix']//div[@class='W_main_half_r']//a[@suda-
    uatrack='key=tblog_service_account&value=view_original_text']")
            for i in t:
                i.click()
            if(t):
                Yuanwen_flag=1
                # print("有 原文 按钮")
            else:
                Yuanwen_flag=0
                # print("无 原文 按钮")
        except:
            Yuanwen_flag=0
            # print("无 原文 按钮")

     ##############################################################################
    ######################
        if(Yuanwen_flag==1): #有     点击全文     按钮
            #被举报的信息
            try:
```

```
 t=driver.find_element_by_xpath("//div[@class='W_layer']//div[@class='layer_feed
feed clearfix']//div[@class='con']")
            # if(t.find('#微博辟谣')):
            #     return
            ## 不实微博文本有无超链接
            if t.text.find('http:')==-1 and t.text.find('https:')==-1:
                message_link_whether=0
            else:
                message_link_whether=1
            people2_wrong_message=t.text[t.text.find(': ')+1:].split('http:')
[0].split('https:')[0]
        except:
            Yuanwen_flag=0
    if(Yuanwen_flag==0): #无    点击全文    按钮
        #被举报的信息
        t=driver.find_element_by_xpath("//div[@class='part_report part_report_alone
clearfix']//div[@class='W_main_half_r']//div[@class='feed bg_orange2
clearfix']//div[@class='con']")
        ## 不实微博文本有无超链接
        if t.text.find('http:')==-1 and t.text.find('https:')==-1:
            message_link_whether=0
        else:
            message_link_whether=1
        people2_wrong_message=t.text[t.text.find(': ')+1:].split('http:')
[0].split('https:')[0]

 ##############################################################################
########################
    #举报人的性别
    people1_sex=driver.find_element_by_xpath("//div[@class='part_report
clearfix']//div[@class='W_main_half_l']//p[@class='mb']//img").get_attribute("title
")
    #举报人网名
    people1_name=driver.find_element_by_xpath("//div[@class='part_report
clearfix']//div[@class='W_main_half_l']//div[@node-
type='report_user_area']//p[@class='mb W_f14']//a").text
    #举报人所在地区
    people1_area=driver.find_element_by_xpath("//div[@class='part_report
clearfix']//div[@class='W_main_half_l']//p[@class='mb']").text
    #被举报人性别
    people2_sex=driver.find_element_by_xpath("//div[@class='part_report
clearfix']//div[@class='W_main_half_r']//p[@class='mb']//img").get_attribute("title
")
    #被举报人网名
    people2_name=driver.find_element_by_xpath("//div[@class='part_report
clearfix']//div[@class='W_main_half_r']//div[@class='user bg_orange2
clearfix']//p[@class='mb W_f14']//a").text
    #被举报人所在地区
```

```
        people2_area=driver.find_element_by_xpath("//div[@class='part_report
    clearfix']//div[@class='W_main_half_r']//p[@class='mb']").text

    # print('1')

        temp=driver.find_elements_by_xpath("//div[@class='part_report
    clearfix']//div[@class='W_main_half_r']//p[@class='mb W_f14']//a")
        #被举报人微博
        people2_weibo=temp[0].get_attribute('href')
        #被举报人的信用等级
        t=driver.find_element_by_xpath("//div[@class='part_report
    clearfix']//div[@class='W_main_half_r']//p[@class='mb
    W_f14']//img").get_attribute('title')
        people2_credit_rating=t.split(': ')[1]


    # print('2')
        #被举报信息原文链接
        try:

     people2_wrong_message_weibo_link=driver.find_element_by_xpath("//div[@class='part_
    report part_report_alone
    clearfix']//div[@class='W_main_half_r']//p[@class='publisher']//a").get_attribute('
    href')
            # people2_delete_or_not='否'
        except:
            people2_wrong_message_weibo_link="###"
            # people2_delete_or_not='是'

        #不实信息发布时间
        t=driver.find_element_by_xpath("//div[@class='part_report part_report_alone
    clearfix']//div[@class='W_main_half_r']//p[@class='publisher']")
        #发布的精确时间
        judge_time_precisely=t.text[t.text.find(': ')+1:].split("|")[0]
        if judge_time_precisely=="被举报微博":
            judge_time_precisely=""
        #发布时间
        judge_time=judge_time_precisely.split(" ")[0]
        if judge_time=="被举报微博":
            judge_time=""

        j=driver.find_element_by_xpath("//div[@class='middle middle_long']//p").text
        #站方判定(大概)
        official_judgement=j[j.find('“')+1:].split('”')[0]
        #站方判定(具体)
        official_judgement_all=j

        #该举报在不实信息网站原文链接
        judge_href=href
```

```
# print('3')

    #被举报人是否是会员
    try:
        try:
            driver.get(people2_weibo)
        except:
            driver.execute_script('window.stop ? window.stop() :
document.execCommand("Stop");')
        # switch_to_active(driver)
        driver.find_element_by_xpath("//a[@title='微博会员']")
        people2_whether_member=1
    except:
        people2_whether_member=0
    # driver.get(href)
    # switch_to_active(driver)
# print('4')

    per_data=[
        people1_name,
        people1_sex,
        people1_area,
        people2_name,
        people2_sex,
        people2_area,
        people2_weibo,
        people2_wrong_message_weibo_link,
        people2_credit_rating,
        people2_whether_member,
        message_link_whether,
        people2_wrong_message,
        judge_href,
        official_judgement,
        official_judgement_all,
        judge_time,
        judge_time_precisely,
        # people2_delete_or_not
    ]

    # print(per_data)
    print("该条信息已经爬完")

    return per_data
```

data_get(driver,href)：

上面的data_explorer的外层函数。由于可能会出现页面一直在加载，但实际上页面的整体内容已经加载出来了的情况，最终会导致浏览器的超时。当浏览器跳转到对应的界面之后，一直如果还在加载并抛出异常的话，就执行相应的js语句，强行停止加载。

```
def data_get(driver,href):
    # tag.click()
    try:
        driver.get(href)
    except:
        driver.execute_script('window.stop ? window.stop() :
document.execCommand("Stop");')
    try:
        return data_explorer(driver,href)
    except:
        print("该条信息爬取失败")
        return
```

main_func：

最终由于cpu资源充足，我们选择利用多进程进行爬取，而main_func就是我们提交给每个进程需要执行的任务。里面涉及到了：

- 对于每个进程的监控：
  - 利用打印的信息，判断进程是否在运行
  - 利用对每个进程设置的日志文件（对应count_txt），判断当前已爬取的页数，以及爬取的每页的数据量
  - 利用日志文件里面开头和结尾的时间信息，判断每个进程最终运行的时间
- 对于爬取的每页数据（一个包含一页所有不实信息条目的href的列表），遍历每一个不实信息条目，运行data_explorer(driver,href)
- 对于每页数据的写入：
  - 由于计算机的 I/O 操作需要占用大量的cpu时间，所以我们选择在爬完一整页之后在进行数据的写入
- 目标500页都爬取完成之后，跳转到一个特殊网页作为标志

```
def main_func(start,need,date,number,cookies,home_page):
    driver=start_webdriver()
    driver.get('https://weibo.com/login.php')
    for i in cookies:
        driver.add_cookie(cookie_dict=i)
    print("第{}号浏览器开启成功".format(number))

    driver.set_page_load_timeout(10)

    # time.sleep(120)
    # for i in cookies:
```

```
        #     driver.add_cookie(i)
        count_txt="count_"+date+"_"+number+".txt"
        with open(count_txt, "a+", newline="") as g:
            writer1 = csv.writer(g)
            writer1.writerow(["第{}号进程正式开始于：{}".format(number,time.ctime())])
            print("第{}号进程正式开始于：{}".format(number,time.ctime()))
            g.close()
        # driver.get('https://www.cnblogs.com/the-only-flash/')
        with open("weiboWrongMessages_"+date+"_"+number+".csv", "a+", newline="") as f:
            writer = csv.writer(f)
            # 确定要爬取什么东西
            writer.writerow([
                "举报人",
                "性别(举)",
                "所在地区(举)",
                "被举报人",
                "性别(被)",
                "所在地区(被)",
                "被举报人的微博主页",
                "被举报内容的微博网址",
                "被举报人信用等级",
                "被举报人是否是微博会员",
                "不实信息内有无超链接",
                "不实信息具体内容",
                "该举报在不实信息网站原文链接",
                "站方判定",
                "站方判定(全)",
                "被举报微博发布时间",
                "被举报微博发布时间(精确)",

                # "被举报人是否注销用户"
                # "被举报人 微博 1",
                # "被举报人 微博 2",
                # "被举报人 微博 3",
                # "被举报人 微博 4",
                #"申诉结果"
            ])
            f.close()
        #用循环实现爬取
        for num in range(start,need+1):
            page_datas=[]
            print("现在开始爬取第{}页".format(num))
            try:
                driver.get( home_page+str(num) )
            except:
                driver.execute_script('window.stop ? window.stop() :
    document.execCommand("Stop");')
            #获取该列表页所有不实信息标签
```

```
 all_tag=driver.find_elements_by_xpath('//div[@class="m_table_tit"]//a[@target="_bl
ank"]')
        haven_count=0

        all_tag_href=[]
        for tag in all_tag:
            all_tag_href.append(tag.get_attribute('href'))

        for href in all_tag_href:
            # driver.get(href)
            haven_count=haven_count+1
            print("第{}页   第{}条    数据".format(num,haven_count))
            #获取页面数据
            data_per=data_get(driver,href)
            if(not data_per):
                print("ERROR")
            page_datas.append(data_get(driver,href))

        #一页的数据压进 csv
        with open("weiboWrongMessages_"+date+"_"+number+".csv", "a+", newline="")
as w:
            writer = csv.writer(w)
            counted=0
            for i in page_datas:
                if(not i):
                    continue
                # print(i)
                counted=counted+1
                writer.writerow(i)
            print("第{}页一共存了{}条数据@@@@@@@@@@@@@@@@".format(num,counted))
            w.close()
        #每获取完一页的数据时候写一次，因为代码的准确性已经可以确定，现在要最求快速
        with open(count_txt, "a+", newline="") as g:
            writer1 = csv.writer(g)
            writer1.writerow(["第{}页已爬完###########  一共存了{}条数据
@@@@@@@@@@@@@@@@".format(num,counted)])
            g.close()

    driver.get('https://www.cnblogs.com/the-only-flash/')
    with open(count_txt, "a+", newline="") as k:
        writer1 = csv.writer(k)
        writer1.writerow(["第{}号进程最终结束于：{}".format(number,time.ctime())])
        print("第{}号进程最终结束于：{}".format(number,time.ctime()))
        k.close()
```

创建多进程：

查阅自己电脑的信息，发现一共有4个逻辑内核，最终选择利用4个进程

```
#start,need,date,number
processes = []
target_pages=500
num=4
average=int(target_pages/num)
date="5_10"
home_page="https://service.account.weibo.com/index?
type=5&status=4&page="#+str(page)
for i in range(num):
    processes.append( Process(target=main_func,args=(average*i+1,average*
(i+1),date,str(i+1),cookies,home_page,)) )
```

小结：

四个进程最终平均运行时间大概为7个小时

所有进程一共爬取了9985条不实信息

下面是第一号进程的运行时间：

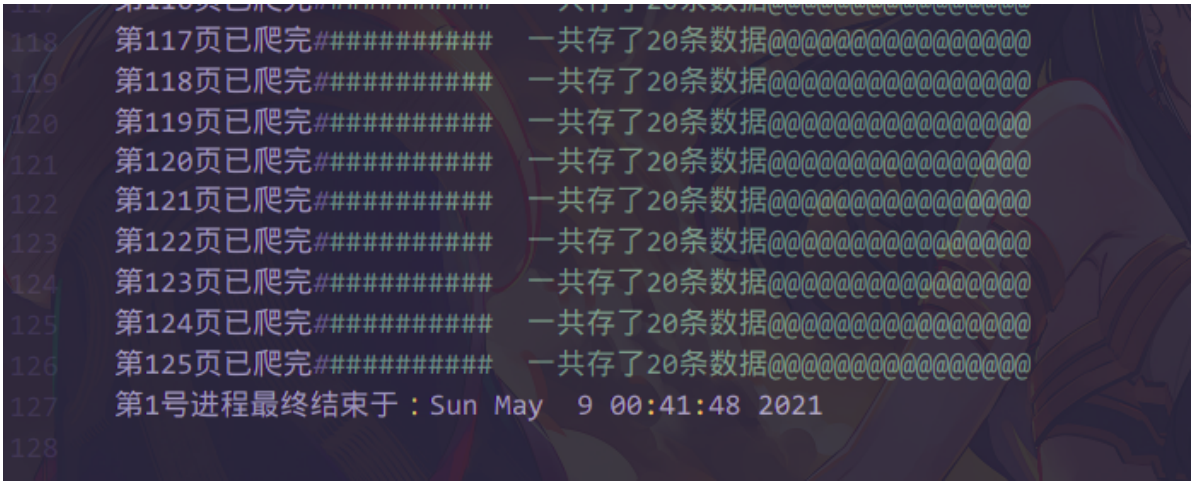

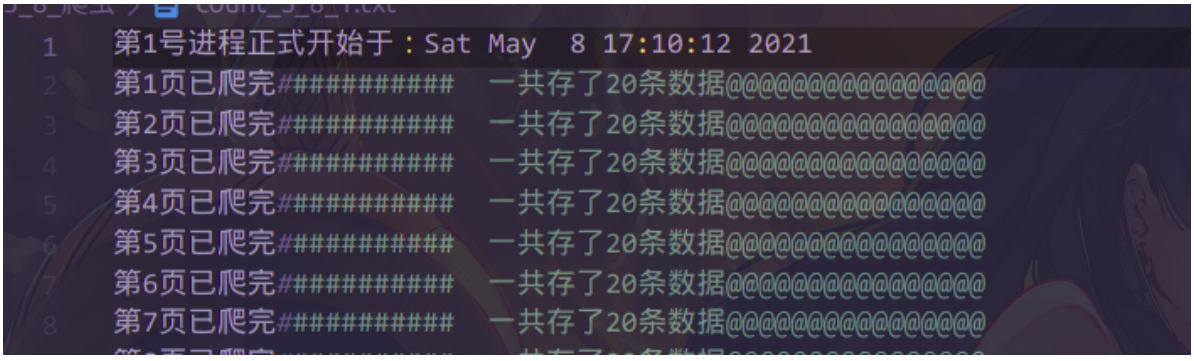

数据处理

🌐数据清洗

1.去重

- 针对爬取到的每条数据，都含有**站方判定**与**被举报微博发布时间**两项特征，我们先对**被举报微博发布时间**进行处理：由于爬取到的**时间**这一特征是具体年月日形式，我们将其按照月为划分，形成一项新的特征——**时间戳**。

	column 16	column 17	column 18
	被举报微博发布时间	被举报微博发布时间(精确)	时间戳
	2021-05-01	2021-05-01 09:01:51	202105
	2021-05-08	2021-05-08 09:45:55	202105
	2021-05-07	2021-05-07 11:02:48	202105
0分钟内生效。	2021-05-02	2021-05-02 17:03:36	202105
	2021-05-02	2021-05-02 13:30:35	202105
	2021-05-09	2021-05-09 12:30:52	202105
	2021-04-12	2021-04-12 19:00:36	202104
	2021-04-12	2021-04-12 20:53:51	202104
	2021-04-09	2021-04-09 00:36:30	202104
	2021-04-01	2021-04-01 12:25:30	202104

- 由于**站方判定**中，微博平台已经将相同的谣言用同一叙述方式总结出，如：博主A发布谣言xxxxabc；博主B发布谣言xxxedf。这两者为同一谣言内容，在微博社区管理中心板块，**大部分不实信息页面中央的站方判定内容中，自动将其归为**

  经查，该微博称“×××”

  例如：

  

  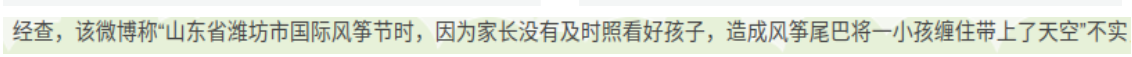

  我们先根据上一步设置的时间戳特征，在相邻两个**时间戳**：即本月、下月两个时间内，进行站方判定内容的相似度对比，相同的或相似度高的数据删除，不同数据保存，每条谣言只保留最早一条数。

  - 我们爬取的结果证明相似微博的站方判定内容 “” 里面的内容基本一致

Ji7a4f	晒晒河北省曲周县依庄乡多个村庄人居住环境
Ji7a4g	晒晒河北省曲周县依庄乡多个村庄人居住环境
Ji7a0g	晒晒河北省曲周县依庄乡多个村庄人居住环境
Ji7a0h	晒晒河北省曲周县依庄乡多个村庄人居住环境
Ji7a0i	晒晒河北省曲周县依庄乡多个村庄人居住环境
Ji7a0j	晒晒河北省曲周县依庄乡多个村庄人居住环境
Ji7ask	晒晒河北省曲周县依庄乡多个村庄人居住环境
Ji7asl	晒晒河北省曲周县依庄乡多个村庄人居住环境

- （伪杰卡德距离）观察我们爬取的数据，由于相似的微博内容中，较短的微博往往更具代表性，并且前半部分（重合部分）往往一致，所以我们选取次数较少的那组数据的模作为分母，在杰卡德距离的基础上做了细微的调整，当然最后必须要保证小于1这个特性。——当然了，不可避免的会出现误删的现象

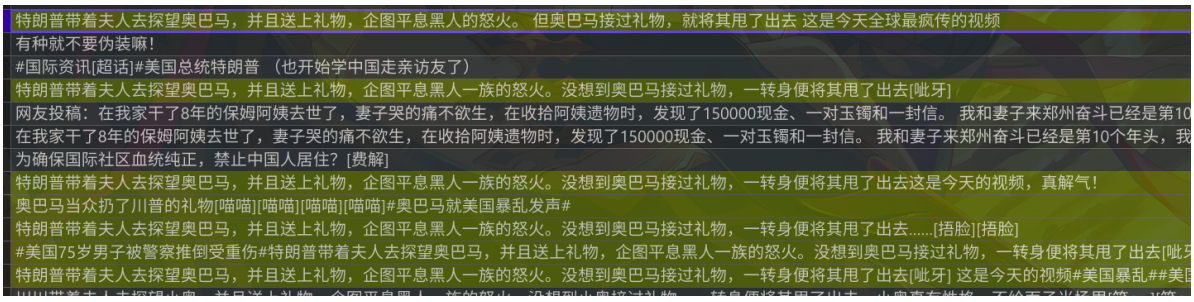

$$J_{原}(A,B)=\frac{|A\bigcap B|}{|A\bigcup B|}\rightarrow J_{伪}(A,B)=\frac{|A\bigcap B|}{\min(|A|,|B|)}$$

code：

```
#计算文本相似度
def calculateSimilarity(s1, s2):# 计算s1在s2中的相似度
    def add_space(s):
        return ' '.join(cleanWord(s))

    # 将字中间加入空格
    s1, s2 = add_space(s1), add_space(s2)

    # 转化为TF矩阵
    from sklearn.feature_extraction.text import CountVectorizer
    cv = CountVectorizer(tokenizer=lambda s: s.split())

    corpus = [s1, s2]
    vectors = cv.fit_transform(corpus).toarray()#转成向量并且放入数组中
    # 求交集
    numerator = 0
    for i in np.min(vectors, axis=0):
        if i != 0:
            numerator+=1
    # 求最小模
    a1=0
    a2=0
    for i in vectors[0]:
        if i !=0 :
            a1=a1+1
    for j in vectors[1]:
        if j !=0 :
            a2=a2+1
    denominator = min(a1,a2)
    # 计算（伪）杰卡德系数
```

```
        return 1.0 * numerator / denominator
```

- 余弦相似度：

爬取正常微博信息

有了上面关于爬取等量正常信息的经验，稍微修改代码过后，就可以得到爬取正常微博的代码。

在爬取正常信息的时候，我们并没有直接爬取之前不实信息发布者的正常微博，具体操作如下：

- 假设原来没有经过去重的所有爬取数据以用户信息来划分后的集合（无重复）为 a ，而经过去重之后剩下的不实微博数据为以用户信息来划分后的集合（无重复） b ，然后我们获得差集 $c = a - b$ 。
- 在差集 c 所包含的用户中，爬取正常的微博信息

最终我们爬取到了736条正常微博信息

> 我们这么处理的原因如下：对于我们确定的那9个数据特征，如果再去获取去重之后剩下的那些用户的正常信息，那么在性别，地区等特征上就会导致重复。

与正常信息爬取有关的代码如下：

- all_5_10.csv是爬取的所有不实信息
- 5_10_corrected_3.csv是经过多次去重之后得到的数据

```
all_data=pd.read_csv("all_5_10.csv")
data=pd.read_csv("5_10_corrected_3.csv")
all_data1=all_data["被举报人的微博主页"]
all_data2=all_data["被举报内容的微博网址"]
all_data3=all_data["被举报人"]
data1=data["被举报人的微博主页"]
data2=data["被举报内容的微博网址"]
data3=data["被举报人"]
cross_data3=list(set(all_data3)^set(data3))
cross_data1=list(set(all_data1)^set(data1))
```

然后我们需要取获取以下数据：

```
def right_get(driver,href,num):
    try:
        driver.get(href)
    except:
```

```
            driver.execute_script('window.stop ? window.stop() :
    document.execCommand("Stop");')
        count=1
        while(count):
            if count > 2:
                break
            try:
                locator=(By.XPATH,"//a[@node-type='feed_list_item_date']")
                element =
    WebDriverWait(driver,3).until(EC.presence_of_element_located(locator))
                break
            except:
                driver.refresh()
                count+=1
                continue
        # tt获取所有的“框”
        tt=driver.find_elements_by_xpath("//a[@node-type='feed_list_item_date']")
        all_href=[]
        for i in tt:
            all_href.append(i.get_attribute("href"))
        # print(len(tt))
        count=0
        message=[]
        for i in all_href:
            try:
                driver.get(i)
            except:
                driver.execute_script('window.stop ? window.stop() :
    document.execCommand("Stop");')
            if count>=1:
                break
            locator=(By.XPATH,"//div[@class='WB_detail']//div[@class='WB_text W_f14']")
            while(1):
                try:
                    element =
    WebDriverWait(driver,3).until(EC.presence_of_element_located(locator))
                    break
                except:
                    driver.refresh()
                    continue
            try:
                driver.find_element_by_xpath("//div[@class='W_tips tips_rederror
    clearfix']")
                continue
            except:
                is_hyperlink=0

         a=driver.find_elements_by_xpath("//div[@class='WB_detail']//div[@class='WB_text
    W_f14']//a")
```

```
 b=driver.find_element_by_xpath("//div[@class='WB_detail']//div[@class='WB_text
W_f14']").text
            for i in a:
                if "L" in i.text:
                    is_hyperlink=1
            b_raw=b
            for i in a:
                b="".join(b.split(i.text))
            if not b_raw:
                message.append("##")
                message.append("##")
                message.append("##")
            else:
                message.append(b)
                message.append(b_raw)
                message.append(is_hyperlink)
            count+=1
            print("第{}条数据  第{}条正常原文".format(num,count))
    return message
```